

NLP

Le NLP est une branche de l'IA qui permet à un ordinateur de traiter et de comprendre les langues humaines. L'objectif est de permettre aux machines de lire, écouter, comprendre et répondre à des informations dans des formats qui sont naturels pour les humains.

1. Introduction au NLP

Applications du NLP :

- Traduction automatique (ex : Google Traduction)
- Analyse de sentiment (ex : analyse des opinions sur les réseaux sociaux)
- Chatbots et assistants virtuels (ex : Siri, Alexa)
- Résumé automatique de texte
- Classification de texte (ex : filtrage de spam)





2. Prétraitement du texte

2.1. Tokenisation

La tokenisation consiste à diviser un texte en mots ou en sous-mots appelés "tokens". Par exemple :

"J'aime les chats."

- Tokens : ["J", "aime", "les", "chats", "."]

2.2. Suppression des mots vides (stopwords)

Les mots vides sont des mots qui n'apportent pas beaucoup de sens (ex : "le", "la", "de", "et", etc.). Ils sont souvent retirés pour réduire la taille du texte tout en conservant son sens.



2. Prétraitement du texte

2.3. Lemmatisation et Stemming

- Lemmatisation : C'est le processus qui consiste à réduire un mot à sa forme de base, ou lemme (ex : "manges" → "manger").
- Stemming : Une approche plus agressive pour couper les mots en leur racine (ex : "manger" → "mang").

2.4. Normalisation

Cela inclut la mise en minuscule, la suppression de la ponctuation et d'autres caractères non pertinents.



3. Représentation des mots

Les mots doivent être représentés sous une forme que les ordinateurs peuvent comprendre. Il existe plusieurs techniques pour cela.

3.1. Bag of Words (BoW)

Cette méthode crée un vecteur représentant un texte où chaque dimension correspond à un mot dans un vocabulaire. La valeur d'une dimension est le nombre de fois où le mot apparaît dans le texte. Cependant, cette méthode ne prend pas en compte l'ordre des mots.

3.2. TF-IDF (Term Frequency-Inverse Document Frequency)

Cela pondère les mots d'un texte en fonction de leur fréquence dans un document et de leur fréquence dans l'ensemble du corpus. Cela aide à évaluer l'importance d'un mot dans un document par rapport à d'autres documents.

3.3. Word Embeddings

Les Word Embeddings sont des représentations vectorielles des mots dans un espace de plus grande dimension. Ces représentations sont apprises automatiquement et capturent des informations contextuelles. Exemples populaires :

- Word2Vec : Utilise des réseaux de neurones pour apprendre des embeddings de mots.
- GloVe : Utilise une matrice de co-occurrence des mots pour créer des embeddings.

3.4. Transformers

Les modèles Transformers sont des modèles d'apprentissage profond qui ont révolutionné le NLP. Un des modèles les plus célèbres utilisant cette architecture est BERT (Bidirectional Encoder Representations from Transformers), qui permet de capturer le contexte des mots à partir de leurs voisins dans une phrase.



4. Modèles et Algorithmes NLP

Il existe plusieurs algorithmes utilisés pour résoudre des tâches NLP spécifiques.

4.1. Analyse de sentiment

L'analyse de sentiment consiste à déterminer si un texte a une tonalité positive, négative ou neutre. Cela est souvent utilisé dans l'analyse d'opinions et de critiques.

4.2. Classification de texte

Les modèles peuvent être utilisés pour classer des textes dans différentes catégories. Par exemple :

- Spam ou Non-Spam
- Thème ou Sujet

4.3. Extraction d'entités nommées (NER)

Cela consiste à identifier des entités spécifiques dans un texte, telles que des noms de personnes, de lieux, de dates, etc.

4.4. Traduction automatique

Les modèles NLP sont utilisés pour traduire des textes d'une langue à une autre, par exemple, Google Translate. Les modèles récents utilisent souvent des architectures seq2seq basées sur des Transformers.

4.5. Résumé automatique

Les systèmes de résumé automatique génèrent un résumé à partir d'un texte long. Il existe deux types :

- Résumé extractif : Extrait des phrases clés du texte.
- Résumé abstractive : Génère des résumés en reformulant le contenu du texte.

Les modèles NLP ont fait un grand bond en avant ces dernières années grâce aux réseaux de neurones et aux architectures Transformer.

5. Modèles NLP Avancés

5.1. GPT (Generative Pretrained Transformer)

Le modèle GPT, dont ChatGPT est basé, est un modèle de génération de texte basé sur l'architecture Transformer. Il peut accomplir des tâches diverses comme répondre à des questions, générer des textes, ou compléter des phrases.

5.2. BERT (Bidirectional Encoder Representations from Transformers)

BERT est un modèle bidirectionnel qui capture mieux le contexte des mots en tenant compte des deux côtés d'un mot dans une phrase.

5.3. T5 (Text-to-Text Transfer Transformer)

T5 est un modèle de traitement du langage qui convertit toutes les tâches NLP en un problème de génération de texte. Par exemple, au lieu de formuler une tâche de classification comme "Quel est le sentiment de ce texte ?", on formule cette tâche comme "Classifie ce texte en positif, négatif ou neutre."

5.4. XLNet, RoBERTa, et autres modèles

Ces modèles sont des variantes de BERT et GPT, optimisés pour des performances encore meilleures.



Les modèles NLP sont utilisés dans de nombreuses applications :

- Chatbots et assistants vocaux : Ces systèmes utilisent le NLP pour comprendre et répondre aux demandes des utilisateurs (par exemple, Siri, Alexa).
- Analyse des sentiments : Utilisé dans l'analyse des critiques de produits, des messages sur les réseaux sociaux, et plus encore.
- Traduction automatique : Des systèmes comme Google Translate et DeepL utilisent des modèles NLP avancés pour traduire des textes d'une langue à une autre.
- Résumé automatique : Les entreprises de médias et les chercheurs utilisent cette technologie pour résumer de grandes quantités de texte.
- Reconnaissance vocale : Convertir la parole en texte, une application courante dans les assistants virtuels et les logiciels de transcription.

Merci