

TP #04 : Techniques de requêtage optimisées

Partie 1: Stratégies de jointure optimisées

Exercice 1.1: Analyse des films populaires et bien notés

Écrivez une requête qui retourne les 20 films les plus populaires (avec plus de 10000 votes) sortis depuis 2000, avec leur note moyenne et leur genre principal.

1. Écrivez la requête initiale en joignant les tables appropriées
2. Exécutez avec EXPLAIN ANALYZE et notez les types de jointures utilisés
3. Ajoutez des index pertinents et mesurez l'amélioration

Exercice 1.2: Acteurs et réalisateurs à succès

Identifiez les acteurs qui ont joué dans au moins 3 films ayant une note supérieure à 8.0. Incluez le nom de ces films.

1. Écrivez la requête en utilisant les tables `title_principals`, `name_basics`, `title_basics` et `title_ratings`
2. Optimisez l'ordre des jointures en utilisant des hints si nécessaire
3. Comparez les plans d'exécution avant/après optimisation

Partie 2: Sous-requêtes et CTE efficaces

Exercice 2.1: Transformation de sous-requêtes

Analysez cette requête qui trouve les films mieux notés que la moyenne de leur genre:

```
SELECT tb.primary_title, tb.start_year, tr.average_rating
FROM title_basics tb
JOIN title_ratings tr ON tb.tconst = tr.tconst
WHERE tr.average_rating > (
    SELECT AVG(r.average_rating)
    FROM title_basics b
    JOIN title_ratings r ON b.tconst = r.tconst
    WHERE b.genres LIKE '%' || tb.genres || '%'
)
ORDER BY tr.average_rating DESC
LIMIT 100;
```

1. Identifiez pourquoi cette requête est inefficace (sous-requête corrélée)
2. Réécrivez-la en utilisant une jointure ou une autre approche plus efficace
3. Comparez les plans d'exécution des deux versions

Exercice 2.2: Utilisation de CTE

Réécrivez la requête optimisée précédente en utilisant une CTE pour calculer la note moyenne par genre.

Puis, développez une requête plus complexe avec plusieurs CTE pour:

1. Calculer les statistiques par genre (note moyenne, nombre de films)
2. Identifier les "films exceptionnels" (dépassant d'au moins 2 points la moyenne de leur genre)
3. Retourner ces films exceptionnels avec leurs acteurs principaux

Partie 3: Window Functions et agrégations avancées

Exercice 3.1: Analyse de carrière avec Window Functions

Pour un acteur donné (ex: "Tom Hanks"), analysez l'évolution de sa carrière:

1. Listez ses films par ordre chronologique
2. Pour chaque film, calculez sa note et incluez:
 - Son classement parmi tous ses films (RANK)
 - La note moyenne mobile sur ses 3 derniers films (AVG OVER)
 - L'écart avec la note de son film précédent (LAG)

Exercice 3.2: Agrégations avancées

Écrivez une requête qui utilise ROLLUP pour analyser les tendances des films:

1. Regroupez les films par décennie et par genre
2. Calculez le nombre de films, la note moyenne et le nombre moyen de votes
3. Incluez les sous-totaux par décennie et le total général
4. Utilisez CASE pour formater lisiblement les résultats NULL du ROLLUP

Partie 4: Pagination et matérialisation

Exercice 4.1: Pagination optimisée

Comparez deux approches pour paginer les résultats d'une recherche de films:

1. Méthode classique avec OFFSET:

```
SELECT primary_title, start_year, genres
FROM title_basics
ORDER BY start_year DESC
LIMIT 10 OFFSET 990; -- Page 100 avec 10 résultats par page
```

2. Méthode par curseur (keyset pagination):

```
-- Pour la page suivante, en supposant que le dernier film vu était de 2015
SELECT primary_title, start_year, genres
FROM title_basics
```

```
WHERE start_year < 2015 OR (start_year = 2015 AND primary_title > 'Z...')
ORDER BY start_year DESC, primary_title
LIMIT 10;
```

Analysez les plans d'exécution et expliquez pourquoi la seconde méthode est plus efficace pour les offsets importants.

Exercice 4.2: Vues matérialisées

Créez une vue matérialisée `film_statistics` qui stocke des statistiques précalculées:

1. Définissez le schéma de la vue (films, notes, genres, statistiques)
2. Créez la vue et des index appropriés
3. Écrivez une requête analytique utilisant cette vue
4. Créez une fonction de rafraîchissement

Partie 5: Requêtes parallèles et analyse de performances

Exercice 5.1: Configuration du parallélisme

Expérimentez avec les paramètres de parallélisme:

1. Affichez et modifiez les paramètres principaux:

```
SHOW max_parallel_workers_per_gather;
SET max_parallel_workers_per_gather = 4;
```

2. Exécutez une requête analytique complexe avec et sans parallélisme:

```
-- Désactiver temporairement
SET max_parallel_workers_per_gather = 0;
-- Puis réactiver et comparer
```

Exercice 5.2: Analyse globale de performances

Pour cette dernière partie, choisissez un cas d'utilisation réel (recherche, recommandation, analyse):

1. Concevez une requête complexe répondant à ce besoin
2. Appliquez plusieurs techniques d'optimisation vues durant le TP
3. Mesurez et documentez l'amélioration à chaque étape
4. Proposez des modifications de modèle qui amélioreraient encore les performances